

Classificação de Tumores Mamários com Machine Learning: Análise do Breast Cancer Wisconsin (Diagnostic) Dataset

Disciplina de Inteligência Artificial — Trabalho Prático em Grupo Grupo 6 — Breast Cancer Dataset (Classificação Binária)

Integrantes: Carlos, Pedro, Luiz, Victor, Vinicius e Wesley

Data: Junho de 2026

Resumo

Este trabalho apresenta um pipeline completo de ciência de dados aplicado ao *Breast Cancer Wisconsin (Diagnostic) Dataset*, disponibilizado pela biblioteca Scikit-Learn. O objetivo é classificar tumores mamários como **malignos** ou **benignos** a partir de 30 atributos extraídos de imagens digitalizadas de aspirados por agulha fina (FNA). Foram conduzidas as etapas de análise exploratória, pré-processamento e modelagem, comparando-se quatro algoritmos de classificação. Os modelos de **Regressão Logística** e **SVM (RBF)** alcançaram acurácia de **98,25%** e ROC-AUC de **0,995** no conjunto de teste, com apenas um falso negativo. Discute-se a relevância da métrica de *recall* da classe maligna no contexto de diagnóstico médico.

Palavras-chave: Machine Learning; Classificação Binária; Diagnóstico de Câncer de Mama; Scikit-Learn.

1. Introdução

O câncer de mama é uma das principais causas de mortalidade entre mulheres no mundo, e o diagnóstico precoce é determinante para o prognóstico. A análise citológica de aspirados por agulha fina (*Fine Needle Aspire* — FNA) permite caracterizar quantitativamente os núcleos celulares presentes em uma amostra tumoral. O *Breast Cancer Wisconsin (Diagnostic) Dataset*, originado dos trabalhos de Wolberg e Mangasarian (1990), reúne essas medições e tornou-se um conjunto de referência para problemas de classificação supervisionada.

O dataset contém **569 amostras** e **30 atributos numéricos** contínuos, derivados de dez características de núcleo celular (raio, textura, perímetro, área, suavidade, compacidade, concavidade, pontos côncavos, simetria e dimensão fractal), reportadas em três agregações: média (*mean*), erro-padrão (*error*) e pior caso (*worst*). O alvo é binário: **maligno** (0) ou **benigno** (1).

Este trabalho tem como objetivo desenvolver e avaliar criticamente modelos de Machine Learning capazes de auxiliar nesse diagnóstico, percorrendo todo o ciclo de um projeto de ciência de dados — do carregamento e exploração dos dados à modelagem, avaliação e interpretação dos resultados.

2. Metodologia

O pipeline foi implementado em Python com as bibliotecas `pandas`, `numpy`, `matplotlib`, `seaborn` e `scikit-learn`, organizado nas oito etapas descritas a seguir.

2.1 Carregamento e exploração

Os dados foram carregados via `sklearn.datasets.load_breast_cancer`. A distribuição das classes (Figura 1) revela **desbalanceamento moderado**: 212 amostras malignas (37,3%) e 357 benignas (62,7%). Esse desbalanceamento, embora não severo, motivou o uso de **estratificação** na divisão treino/teste e a análise de métricas além da acurácia.




Figura 1 — Distribuição das classes do diagnóstico.

A análise de correlação (Figura 2) evidenciou forte associação entre o diagnóstico e atributos de **tamanho e forma do núcleo**. Os dez atributos mais correlacionados com o alvo foram, em ordem decrescente de magnitude: `worst concave points` (−0,79), `worst perimeter` (−0,78), `mean concave points` (−0,78), `worst radius` (−0,78), `mean perimeter` (−0,74), `worst area`

(-0,73), mean radius (-0,73), mean area (-0,71), mean concavity (-0,70) e worst concavity (-0,66). A correlação negativa indica que valores maiores desses atributos estão associados a tumores **malgnos**. Observou-se ainda forte **multicolinearidade** entre os grupos radius / perimeter / area , esperada por descreverem geometricamente a mesma estrutura.




Figura 2 — Mapa de calor da correlação entre os 30 atributos.

2.2 Estatísticas descritivas

As estatísticas descritivas confirmaram a **heterogeneidade de escalas** entre os atributos — por exemplo, mean area na ordem de centenas frente a mean smoothness na ordem de 0,1. A detecção de outliers pela regra do IQR ($1,5 \times \text{IQR}$) apontou area error (11,4%), radius error (6,7%) e perimeter error (6,7%) como os atributos com mais valores extremos. Tais outliers foram considerados **cl clinicamente plausíveis** (tumores atípicos) e não erros de medição, sendo, portanto, mantidos. As distribuições e os outliers são visualizados nas Figuras 3 e 4.




Figura 3 — Histogramas de distribuição dos 30 atributos.




Figura 4 — Boxplots dos atributos padronizados (z-score).

A separabilidade entre classes é evidenciada nos gráficos de dispersão e no pairplot (Figuras 5 e 6): tumores malignos concentram-se em valores mais altos de raio, perímetro, concavidade e pontos côncavos, com sobreposição apenas parcial.




Figura 5 — Dispersão entre pares de variáveis relevantes, por classe.




Figura 6 — Pairplot dos principais atributos, colorido por classe.

2.3 Pré-processamento e divisão dos dados

O dataset **não possui valores faltantes** em **variáveis categóricas**. Aplicou-se a **padronização** com `StandardScaler` (média 0, desvio 1), justificada pela disparidade de escalas e pela sensibilidade dos algoritmos baseados em distância (KNN, SVM) e em otimização (Regressão Logística). O *scaler* foi ajustado **exclusivamente no conjunto de treino**, evitando vazamento de informação (*data leakage*).

Os dados foram divididos em **80% treino (455 amostras)** e **20% teste (114 amostras)**, com `random_state=42` e **estratificação** pelas classes, o que preservou a proporção de ~37%/63% em ambos os conjuntos.

2.4 Modelagem e avaliação

Foram implementados e comparados **quatro classificadores** (acima do mínimo de dois exigido): **Regressão Logística**, **K-Nearest Neighbors (k=5)**, **Random Forest (300 árvores)** e **SVM** com kernel RBF. Utilizou-se **validação cruzada (cv=5)** no treino para uma estimativa robusta, e a

avaliação final no conjunto de teste empregou as métricas de **acurácia, precisão, recall, F1-score, ROC-AUC e matriz de confusão**.

3. Resultados

A Tabela 1 apresenta o desempenho na validação cruzada (cv=5) sobre o conjunto de treino.

Tabela 1 — Validação cruzada (cv=5), conjunto de treino

Modelo	Acurácia (média ± desvio)	F1 (média ± desvio)
Regressão Logística	0,9802 ± 0,0128	0,9843 ± 0,0101
SVM (RBF)	0,9714 ± 0,0179	0,9773 ± 0,0140
KNN	0,9670 ± 0,0209	0,9741 ± 0,0164
Random Forest	0,9582 ± 0,0224	0,9668 ± 0,0174

A Tabela 2 consolida as métricas no **conjunto de teste**. A coluna *Recall maligno* corresponde à sensibilidade para a classe de maior gravidade clínica.

Tabela 2 — Métricas no conjunto de teste (114 amostras)

Modelo	Acurácia	Precisão	Recall	F1	Recall maligno	ROC-AUC
Regressão Logística	0,9825	0,9861	0,9861	0,9861	0,9762	0,9954
SVM (RBF)	0,9825	0,9861	0,9861	0,9861	0,9762	0,9950
KNN	0,9561	0,9589	0,9722	0,9655	0,9286	0,9788
Random Forest	0,9474	0,9583	0,9583	0,9583	0,9286	0,9937

As Figuras 7, 8 e 9 ilustram, respectivamente, a comparação das métricas, as matrizes de confusão e as curvas ROC.




Figura 7 — Comparação das métricas entre os modelos no conjunto de teste.




Figura 8 — Matrizes de confusão dos quatro modelos.




Figura 9 — Curvas ROC e respectivos valores de AUC.

A importância de atributos segundo o Random Forest (Figura 10) reforça os achados da EDA: `worst concave points`, `worst perimeter`, `worst area` e `mean concave points` figuram entre os mais determinantes.




Figura 10 — Top 15 atributos mais importantes (Random Forest).

4. Discussão

Todos os modelos atingiram desempenho elevado (acurácia $\geq 0,94$; ROC-AUC $\geq 0,97$), confirmando a boa separabilidade observada na análise exploratória. A **Regressão Logística** e o **SVM (RBF)** lideraram, com acurácia de **98,25%** e apenas **dois erros** em 114 amostras de teste. O fato de um modelo linear simples igualar o SVM sugere que as classes são, em grande medida, **linearmente separáveis** no espaço padronizado — resultado coerente com a estrutura dos dados.

No contexto de **diagnóstico médico**, a métrica mais crítica é o **recall da classe maligna** (sensibilidade), pois um **falso negativo** — classificar como benigno um tumor maligno — pode atrasar o tratamento e ter consequências graves. Os melhores modelos atingiram recall maligno de **0,976**, equivalente a **um único falso negativo** no conjunto de teste. A padronização mostrou-se decisiva para o desempenho dos modelos baseados em distância e otimização.

5. Conclusão

O trabalho demonstrou, de ponta a ponta, a aplicação de um pipeline de Machine Learning a um problema real de diagnóstico médico, com resultados consistentes e elevada acurácia. Um classificador como o desenvolvido pode atuar, na prática profissional, como **sistema de apoio à decisão** — auxiliando radiologistas e patologistas na **triagem** e priorização de casos suspeitos —, sempre como ferramenta complementar e **nunca em substituição ao laudo médico**.

Como **limitações**, destacam-se: o tamanho reduzido e a origem única do conjunto de dados, que limitam a generalização; a ausência de otimização exaustiva de hiperparâmetros (oportunidade para `GridSearchCV`); e a não consideração explícita do **custo assimétrico dos erros** (falso negativo >> falso positivo), que poderia ser tratada com ajuste do limiar de decisão. Como trabalhos futuros, sugere-se a validação em bases externas, a calibração de probabilidades e a análise de interpretabilidade (ex.: SHAP) para uso clínico responsável.

6. Referências

GÉRON, A. **Mãos à Obra: Aprendizado de Máquina com Scikit-Learn, Keras e TensorFlow**. 2. ed. Rio de Janeiro: Alta Books, 2021.

McKINNEY, W. **Python para Análise de Dados**. 2. ed. São Paulo: Novatec, 2018.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.

RASCHKA, S.; MIRJALILI, V. **Python Machine Learning**. 3. ed. Birmingham: Packt Publishing, 2019.

SCIKIT-LEARN DEVELOPERS. **Toy Datasets — Scikit-Learn Documentation**. Disponível em: https://scikit-learn.org/stable/datasets/toy_dataset.html. Acesso em: jun. 2026.

WOLBERG, W. H.; MANGASARIAN, O. L. Multisurface method of pattern separation for medical diagnosis applied to breast cytology. **Proceedings of the National Academy of Sciences**, v. 87, n. 23, p. 9193–9196, 1990.