

Explorando Toy Datasets do Scikit-Learn

Breast Cancer Wisconsin (Diagnostic) Dataset

Grupo 6 — Classificação Binária


Carlos · Pedro · Luiz · Victor · Vinicius · Wesley

Disciplina de Inteligência Artificial · Junho/2026

1. O problema e o dataset

- **Tema:** diagnóstico de câncer de mama (maligno × benigno)
- **Origem:** medições de núcleos celulares em aspirados por agulha fina (FNA)
- **569 amostras · 30 atributos** numéricos contínuos
 - 10 características × 3 agregações (*mean, error, worst*)
- **Alvo binário:** 0 = maligno · 1 = benigno
- **Relevância:** diagnóstico precoce é determinante para o prognóstico

2. EDA — Balanceamento das classes




Desbalanceamento **moderado** (37% maligno / 63% benigno) → uso de **estratificação** e métricas além da acurácia.

2. EDA — Correlação com o diagnóstico


Atributos mais associados ao alvo:

- worst concave points (-0,79)
- worst perimeter (-0,78)
- mean concave points (-0,78)
- worst radius (-0,78)

Forte **multicolinearidade** entre radius / perimeter / area .



3. Separabilidade das classes



Tumores malignos → valores maiores de raio, perímetro e concavidade.

4. Pré-processamento e split

- **Sem valores faltantes e sem variáveis categóricas**
- **Padronização** com `StandardScaler` (média 0, desvio 1)
 - Necessária pela disparidade de escalas (ex.: `mean area` vs. `mean smoothness`)
 - Ajustada **só no treino** → evita *data leakage*
- **Split 80/20** estratificado, `random_state=42`
 - Treino: 455 · Teste: 114 (proporção de classes preservada)

5. Modelagem — 4 algoritmos comparados

Modelo	CV Acurácia (cv=5)	CV F1
Regressão Logística	0,9802 ± 0,013	0,9843
SVM (RBF)	0,9714 ± 0,018	0,9773
KNN (k=5)	0,9670 ± 0,021	0,9741
Random Forest	0,9582 ± 0,022	0,9668



Validação cruzada (cv=5) sobre o conjunto de treino.

6. Resultados no conjunto de teste

Modelo	Acurácia	F1	Recall maligno	ROC-AUC
Regressão Logística	0,9825	0,9861	0,9762	0,9954
SVM (RBF)	0,9825	0,9861	0,9762	0,9950
KNN	0,9561	0,9655	0,9286	0,9788
Random Forest	0,9474	0,9583	0,9286	0,9937

Melhores modelos: **apenas 2 erros em 114 amostras.**

6. Curvas ROC e matrizes de confusão



7. Por que o *recall maligno* importa?

- Em diagnóstico médico, o erro mais grave é o **falso negativo**
 - (câncer classificado como benigno → atraso no tratamento)
- Melhores modelos: **recall maligno = 0,976** → **1 falso negativo** no teste
- **Aplicação real:** sistema de **apoio à decisão** para triagem
 - complementar ao laudo médico, **nunca substituto**

8. Conclusões e limitações

Conclusões

- Pipeline completo com **acurácia de 98,25%** e ROC-AUC de 0,995
- Classes praticamente **linearmente separáveis** após padronização

Limitações & trabalhos futuros

- Dataset pequeno e de fonte única → validar em bases externas
- Otimizar hiperparâmetros (`GridSearchCV`)
- Tratar **custo assimétrico** dos erros (ajuste de limiar) e interpretabilidade (SHAP)

Obrigado!

Perguntas?

Grupo 6 — Breast Cancer Dataset · Inteligência Artificial