

# Explorando Toy Datasets do Scikit-Learn

## Breast Cancer Wisconsin (Diagnostic) Dataset

### Grupo 2 — Classificação Binária

Carlos Henrique Fernandes Rodrigues · Pedro Campos Canafistula Oliveira · Luiz Henrique Alves Rodrigues


Victor Nogueira da Nova Bonato · Vinicius Lacerda de Souza · Wesley Messias Moreira Brito · Lucas Ferreira Coelho

Disciplina de Inteligência Artificial · Junho/2026

# 1. O problema e o dataset

- **Tema:** diagnóstico de câncer de mama (maligno × benigno)
- **Origem:** medições de núcleos celulares em aspirados por agulha fina (FNA)
- **569 amostras · 30 atributos** numéricos contínuos
  - 10 características × 3 agregações (*mean, error, worst*)
- **Alvo binário:** 0 = maligno · 1 = benigno
- **Relevância:** diagnóstico precoce é determinante para o prognóstico

## 2. EDA — Balanceamento das classes




Desbalanceamento **moderado** (37% maligno / 63% benigno) → uso de **estratificação** e métricas além da acurácia.

## 2. EDA — Correlação com o diagnóstico


Atributos mais associados ao alvo:

- worst concave points (-0,79)
- worst perimeter (-0,78)
- mean concave points (-0,78)
- worst radius (-0,78)

Forte **multicolinearidade** entre radius / perimeter / area .



### 3. Separabilidade das classes



Tumores malignos → valores maiores de raio, perímetro e concavidade.

## 4. Pré-processamento e split

- **Sem valores faltantes e sem variáveis categóricas**
- **Padronização** com `StandardScaler` (média 0, desvio 1)
  - Necessária pela disparidade de escalas (ex.: `mean area` vs. `mean smoothness`)
  - Ajustada **só no treino** → evita *data leakage*
- **Split 80/20** estratificado, `random_state=42`
  - Treino: 455 · Teste: 114 (proporção de classes preservada)

## 5. Modelagem — 4 algoritmos comparados

| Modelo              | CV Acurácia (cv=5) | CV F1  |
|---------------------|--------------------|--------|
| Regressão Logística | 0,9802 ± 0,013     | 0,9843 |
| SVM (RBF)           | 0,9714 ± 0,018     | 0,9773 |
| KNN (k=5)           | 0,9670 ± 0,021     | 0,9741 |
| Random Forest       | 0,9582 ± 0,022     | 0,9668 |

Validação cruzada (cv=5) sobre o conjunto de treino.



## 6. Resultados no conjunto de teste

| Modelo              | Acurácia | F1     | Recall maligno | ROC-AUC |
|---------------------|----------|--------|----------------|---------|
| Regressão Logística | 0,9825   | 0,9861 | 0,9762         | 0,9954  |
| SVM (RBF)           | 0,9825   | 0,9861 | 0,9762         | 0,9950  |
| KNN                 | 0,9561   | 0,9655 | 0,9286         | 0,9788  |
| Random Forest       | 0,9474   | 0,9583 | 0,9286         | 0,9937  |

Melhores modelos: **apenas 2 erros em 114 amostras.**



# 6. Curvas ROC e matrizes de confusão



## 7. Por que o *recall maligno* importa?

- Em diagnóstico médico, o erro mais grave é o **falso negativo**
  - (câncer classificado como benigno → atraso no tratamento)
- Melhores modelos: **recall maligno = 0,976** → **1 falso negativo** no teste
- **Aplicação real:** sistema de **apoio à decisão** para triagem
  - complementar ao laudo médico, **nunca substituto**

## 8. Conclusões e limitações

### Conclusões

- Pipeline completo com **acurácia de 98,25%** e ROC-AUC de 0,995
- Classes praticamente **linearmente separáveis** após padronização

### Limitações & trabalhos futuros

- Dataset pequeno e de fonte única → validar em bases externas
- Otimizar hiperparâmetros ( `GridSearchCV` )
- Tratar **custo assimétrico** dos erros (ajuste de limiar) e interpretabilidade (SHAP)

# Obrigado!

## Perguntas?

Grupo 2 — Breast Cancer Dataset · Inteligência Artificial